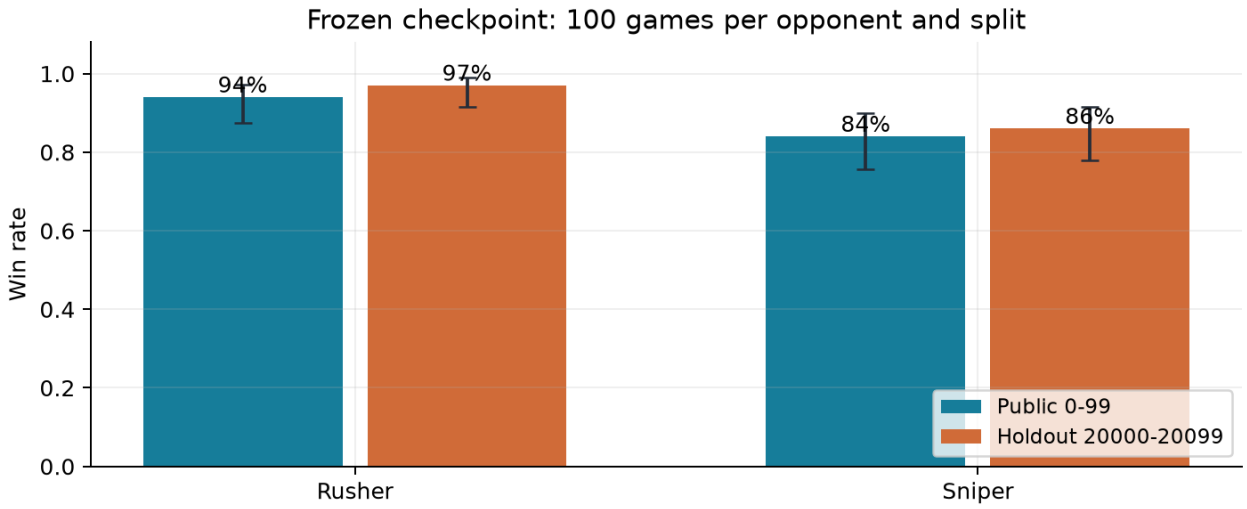
Astro Party：規則輔助 PPO 實驗報告

日期：2026/11/01 ｜ 執行環境：本機 CPU ｜ 範圍：Astro Party

1. 結果與研究問題

目標是以同一份 SB3 模型擊敗 Rusher 與 Sniper。固定 checkpoint 的公開成績為 5/10；計分門檻分別為 90% 與 85%。下面全部是實際載入儲存模型後的對戰結果，並非教師策略成績。

測試集	對手	勝場	勝率	Wilson 95%	門檻
公開 0–99	Rusher	94/100	94%	87.5%–97.2%	達標
公開 0–99	Sniper	84/100	84%	75.6%–89.9%	未達標
保留 20000–20099	Rusher	97/100	97%	91.5%–99.0%	達標
保留 20000–20099	Sniper	86/100	86%	77.9%–91.5%	達標



圖中誤差棒為單一測試集二項比例的 Wilson 95% 區間；它不涵蓋跨訓練 seed 的不確定性。額外保留集不等於助教的私有測試，亦不能保證班級 round robin 排名。

方法與完成狀態的界線

最終方案是手工戰術特徵 + 行為模仿初始化 + 真正的 PPO 更新。策略主要先驗來自可解釋控制器，不宣稱端到端從零學習。本次沒有處理 2048；報告需與 2048 部分合併後才是整份作業報告。

W&B：尚未驗證雲端同步；完整 offline run 與 TensorBoard 紀錄已保留。新環境 API 檢查回報尚未設定憑證，需完成本機登入後同步。

2. 遊戲機制與 baseline 分析

每步動作為 [turn, thrust, shoot_signal]，前兩項裁切至 [-1,1]，第三項大於零即射擊。回合最長 1500 步，draw 不算勝。擊毀飛船僅使對手變為逃生員；需再次命中或以飛船撞擊逃生員，才算最終勝利。逃生員存活 200 步後重生。

機制	對策略的影響
84 維觀測；x / 600、y / 400	先還原世界座標再計算角度，否則瞄準方向錯誤。
子彈速度 620 px/s；彈匣 3 發	需要提前瞄準，避免無效連射耗盡彈藥。
轉向上限 3.5 rad/s；每秒 50 步	每步最多轉 0.07 rad；遊戲先轉向再開火。
行星、掩體與隕石會擋子彈	須檢查射線；遮擋時需繞行而非直線硬推。
飛船慣性與倒車推力減半	閃避必須預測速度變化，單純距離判斷不足。

兩個 baseline 的差異

Rusher 使用 120–260 px 作戰距離、較寬鬆的 1.3 射擊容忍係數，且不做子彈閃避。Sniper 使用 380–620 px、較嚴格的 0.8 容忍係數，並搜尋候選動作來避開子彈。兩者共用遮擋繞行、追擊逃生員與自身出艙逃生邏輯。

實際檢驗的改進假設

第一，射擊判定應使用本步轉向之後的角度，且閃避改變轉向後必須重新檢查射擊。第二，baseline 先按「當前漂移軌跡」篩選威脅，可能漏掉轉向後才會撞上的子彈；改為對所有可見敵彈檢查候選軌跡。第三，18 步的預測視野偏短，延長可較早閃避。

近距離追擊曾被視為可能破解 Sniper，但診斷對戰並不支持：近距版本在 12 場 Sniper 對戰僅贏 4 場。提高勝率主要來自更完整的防禦預測，而不是一味前衝。提前瞄準乘上 0.8 是驗證選出的啟發式修正，不是物理定律。

3. 可解釋控制器與神經網路

DefenseBot：公開觀測 → 控制建議

先將觀測還原至世界單位，依自身 / 對手是否出艙選擇逃生、追擊或對射。對射保持約 500–700 px，遇遮擋則沿用 baseline 的繞行方式。利用常速度截擊方程估計目標未來位置，速度提前量乘以 0.8；射擊還須滿足視線與角度條件。

對所有觀測到的敵彈，先模擬原建議動作的最小距離。若不夠安全，搜尋 turn ∈ {-1,-0.5,0,0.5,1}、thrust ∈ {-1,0,1} 共 15 種組合；以 60 步（1.2 秒）的預測最小距離評分，加入小幅偏離原轉向的代價。飛船使用 35 px 安全界線，逃生員為 28 px。

此模擬只近似自身運動與已存在子彈的直線運動，沒有完整模擬牆體碰撞，也沒有預知對方尚未發射的子彈。控制器只讀取觀測與公開常數，不讀取測試種子、對手名稱或隱藏狀態。

元件	實際設計
輸入	原始 Box(84,)；沒有外部 VecNormalize
TacticalFeatures	3 維規則控制建議 + 前 26 維自身 / 對手狀態 = 29 維
Actor	SB3 內建 MlpPolicy；29 → 3 線性輸出，再由 SB3 裁切
Critic	29 → 64 → 64 → 1，Tanh activation
可訓練參數	6,238，包含 actor、critic 與 3 維 log_std
模型載入	原生 PPO.load()；沒有覆寫 predict()

為什麼這樣設計

幾何 MLP 的短跑雖降低模仿誤差，仍會因轉向精度、射擊時機與軌跡分布偏移而失敗。規則特徵把可解釋先驗保留在模型內，使 CPU 上的小網路能學習動作校正。所有最終動作仍經過訓練過的 actor；但不能據此說高階戰術都是神經網路自己學會的。

特徵類別與教師定義位於訓練檔中，執行為 __main__ 後由 cloudpickle 存入 SB3 zip。只快取純函數特徵以加速 PPO 重複讀取 rollout；快取不改變輸出，也不構成跨回合記憶。

4. Reward、模仿初始化與 PPO 設定

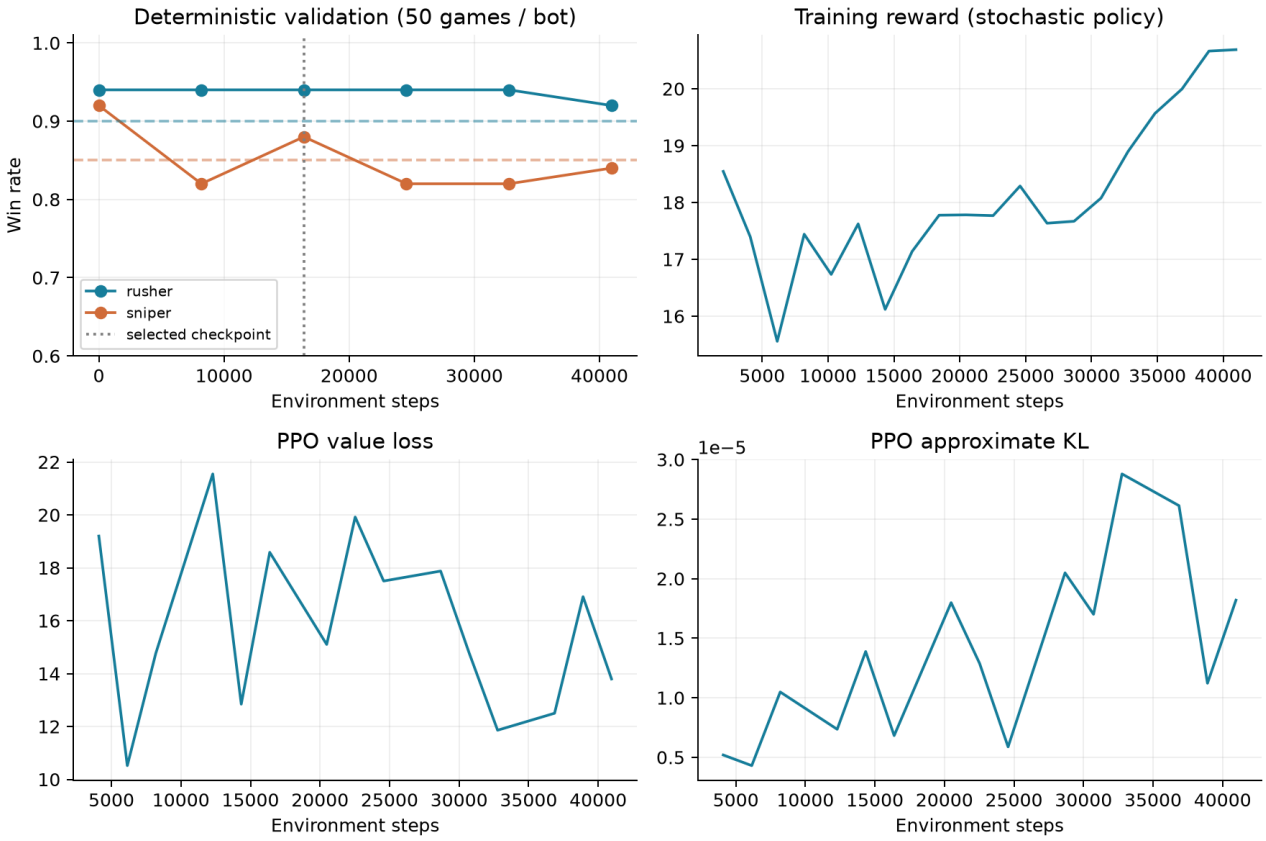
訓練 reward 項目	數值 / 說明
最終擊殺 / 自身被殺	+20 / -20
擊毀飛船 / 自身被擊毀	+3 / -3
取得 laser	+0.1
每步成本	-0.002
接近 shaping	0.5 × 權重 × (前一步距離 - 本步距離)，距離除以 600
shaping 權重	一般 +1；追擊逃生員 +4；自身出艙 -1
重生 / 擊中隕石	0；避免反覆重生或打石頭刷分

這個距離 shaping 不是嚴格的 potential-based reward：狀態權重會切換，也沒有以 gamma 修正勢能差，因此不宣稱保持最優策略不變。評分與選模始終使用原版環境的最終擊殺結果。

參數	實際值
訓練種子 / 對手抽樣	seed 42；環境 RNG 起點 100042；Rusher / Sniper 各 50%
模仿初始化	10,000 個教師步；120 epochs；Adam lr 0.003；batch 約 256
PPO / CPU	4 個 subprocess env；每個 env n_steps 512；torch threads 1
更新	batch 256；每個 rollout 5 epochs；lr 1e-6
折扣與裁切	gamma 0.995；GAE lambda 0.95；clip 0.1；target KL 0.02
探索	log_std 初值 -3.5；entropy coefficient 0
驗證與選模	每 8,192 步測各 50 局；最大化 min(R/0.90,S/0.85)
本次選中 checkpoint	第 2 輪，PPO 累積 16,384 步；完整 run 共 40,960 步

另測試 AnchoredPPO：標準 PPO 更新後，將 actor 參數收縮為 prior + 0.1 × (更新後參數 - prior)。此為額外的保守先驗，僅改變學習；並未用它取代評分時的 predict。它在選模驗證未明顯優於較簡單的普通 PPO，因此最終提交選普通 PPO。

5. 訓練曲線與失敗實驗



上圖是最終候選 run 6o6gk5el 的實際紀錄。步數 0 表示模仿初始化完成，不是未訓練隨機模型；之後才是 PPO。虛線為兩個門檻，垂直線為選中的 16,384 步 checkpoint。較晚的 checkpoint 並不一定更好。

實驗	驗證局數 / 對手	選中 Rusher / Sniper
幾何特徵 + BC + PPO · r5zt1smk	12	8.3% / 8.3%
初版規則特徵 PPO · fcxyratm	12	83.3% / 58.3%
25 步防禦 PPO · 9hb3syt0	50	96% / 76%
60 步防禦 PPO · 6o6gk5el	50	94% / 88%
收縮式 PPO · yffn89i2	50	見完整 run；未選為最終模型

這是逐步開發紀錄，不是嚴格控制所有變因的因果消融：不同實驗的教師、探索量、局數與學習率也有變。不能將差異全部歸因於預測視野，也不能把 12 場與 50 場的比例視為等精度。

模仿後、PPO 前的 50 場驗證為 Rusher 94%、Sniper 92%；選中的 PPO 為 94%、88%。因此本次沒有證據顯示 PPO 比教師 / 模仿初始化更強。實證支持的是「手工先驗提供主要能力，而保守 PPO 能保留可通過門檻的策略」，不能誇大強化學習的貢獻。

6. 測試隔離、重現與 W&B

固定模型之後才測公開與保留集

同一 checkpoint 在驗證 10000–10099 上為 Rusher 93%、Sniper 89%。公開 0–99 與保留 20000–20099 都在固定模型後才執行，未用於逐輪選模。

乾淨檢查資料夾只包含原版評分程式、原版遊戲 / renderer / env package、原版 baseline 與提交模型。由於原版 envs/__init__.py 會 import 訓練環境，因此也放入原版訓練環境；沒有放入本次修改的訓練檔或 experiments。

受保護的 game.py、eval_astro_party_env.py、eval_astro_party.py、sniper_bot.py、rusher_bot.py 的 SHA-256 均與修改前相同。逐局評估 JSON 另外記錄 checkpoint hash，可核對兩個測試集使用完全相同的模型。

模型 SHA-256：7822ea5d14e41cfab86099de0766c5e51906d66e5ebfb846ce9fb4976bb90fba

重現入口

在 astro_party 目錄執行 run_training.ps1 -Mode online -Epochs 5；具體命令與版本鎖定見 README_TW.md、requirements-lock.txt。模型儲存為 models/model_astro_party.zip；官方評分指令為 python eval_astro_party.py --model models/model_astro_party.zip。保留測試再加 --seed-base 20000。

W&B 圖表與同步

project：astro-party-hw3。訓練開始前呼叫 wandb.init，記錄 config、bc/mse、reward、episode length、PPO policy / value loss、KL、探索 std 與雙對手勝率。採用 global_step 對齊訓練曲線，checkpoint 與逐局評估另存 artifact / table。

尚未驗證雲端同步；完整 offline run 與 TensorBoard 紀錄已保留。新環境 API 檢查回報尚未設定憑證，需完成本機登入後同步。

若未同步：在根目錄執行 .venv311/Scripts/wandb.exe login，再進入 astro_party 執行 sync_wandb.ps1。不要把 API key 寫進程式。初期兩個 pilot 的訓練已執行，但結尾 artifact 暫存權限失敗；後續以工作目錄內的 WANDB_DATA_DIR / WANDB_CACHE_DIR 修正。

實際產出

兩個訓練檔、模型 zip、My Plan、繁體中文 Markdown / PDF 報告、訓練與測試圖表、完整原始紀錄、CPU 重現與同步腳本。本次未提供學號，沒有建立冒充完整作業的學號提交包。

7. 限制、可解釋性與後續工作

這份實驗能支持什麼

本次以觀測可得的物理量與 baseline 程式設計一個規則輔助策略，並用 SB3 執行模仿初始化及 PPO 訓練。報告的成績來自原版對戰介面，而不是修改評分器或偷偷覆寫 predict。模型小、戰術可追溯，適合逐項解釋。

仍有哪些限制

只有一個主要訓練 seed，不能據此估計跨 seed 穩定性。驗證集用於選參數和 checkpoint，會產生選擇偏差；信賴區間只適用於已固定模型的單一測試集。兩個對手都是公開規則 bot，對未知學生模型的泛化能力尚未測試。

控制器的避彈模擬忽略障礙碰撞及未來新子彈；遮擋繞行與出艙逃生仍沿用原 baseline 的近似。線性 actor 的校正能力有限，微小轉向偏移也可能引發截然不同的後續軌跡。原始 MLP 的低 BC loss 沒有轉化為勝率，顯示離線動作誤差與長期策略表現必須分開評估。

README 允許閱讀 / 模仿 bot、SB3 內建 policy 與訓練檔內的自訂特徵擷取器；本方案據此實作。但未取得完整投影片，若投影片另禁止規則特徵或對 LLM 有額外規範，需依課程規定調整；不可聲稱已核對未提供的規則。

若還有更多計算時間

優先做多訓練 seed、凍結後的更大獨立測試，以及完整牆體碰撞感知的避彈。若需純神經策略，可用 DAgger 收集自身偏離教師軌跡後的標記，對射擊正例重採樣並增加瞄準精度；但本次沒有執行這些完整實驗，不能把它們寫成已證實有效。

參考與協作揭露

遊戲 / 門檻 / 提交限制：本作業 README.md、envs/game.py、eval_astro_party.py、models/sniper_bot.py、models/rusher_bot.py。

SB3 官方 Policy Networks 文件：https://stable-baselines3.readthedocs.io/en/master/guide/custom_policy.html。使用內建 MlpPolicy、policy_kwargs 與 BaseFeaturesExtractor。

W&B 記錄介面依已安裝 0.31.0 SDK 與 wandb sync --help 驗證；完整套件版本見 requirements-lock.txt。

本次計畫、程式實作、實驗分析與報告由使用者委託 AI 協作完成。使用者應理解方法、核對課程 LLM 使用政策，並按規定揭露協作。未偽造訓練曲線、勝率或雲端上傳狀態。